Universidad Nacional de Colombia
Sede Medellín
Facultad de Ciencias
Departamento de Estadística

El test exacto de Fisher en tablas 2×2 pequeñas: cuándo condicionar y qué alternativas considerar

Un ensayo clínico, una enumeración exacta y algunas hipótesis sobre su uso habitual

Esneider Ríos

Medellín, 2026

Resumen

El test exacto de Fisher es la recomendación habitual para tablas 2×2 con pocas observaciones. Su cálculo es exacto y su error tipo I nunca excede el nivel nominal; sin embargo, ambas garantías se obtienen condicionando a los dos márgenes de la tabla, y en muchos diseños el total de respuestas no lo fija el protocolo sino el azar. Este trabajo examina qué implica esa elección bajo el modelo de dos binomiales independientes. Se revisan las alternativas exactas incondicionales (Barnard–CSM, Boschloo, Suissa–Shuster, Berger–Boos, el m-test) y la corrección mid-p, y se analiza un ensayo pediátrico aleatorizado ($7/34$ frente a $1/34$) en el que Fisher da $p = 0{,}054$ y Boschloo $p = 0{,}038$. Todas las cifras provienen de la enumeración exacta de las tablas posibles. Un argumento breve muestra que la región de rechazo de Fisher está siempre contenida en la de Boschloo; la enumeración lo confirma en 51 diseños balanceados, de 10 a 60 participantes por grupo, y mide la diferencia. En los cuatro diseños en que se trazó la superficie de potencia (15, 25, 34 y 50 por grupo), donde la potencia de Fisher está entre 0,2 y 0,8, la ganancia mediana de Boschloo fue de 5 a 14 puntos porcentuales; entre 15 y 50 por grupo, el tamaño real de Fisher no superó 0,038, y el de Boschloo se mantuvo entre 0,041 y 0,0497, sin exceder nunca $\alpha = 0{,}05$. El mismo intercambio entre garantía e información reaparece en la estimación: según la corrección elegida, la razón de odds estimada va de 4,9 a 8,6, mientras que la diferencia de riesgos apenas cambia. Leídos en esa escala, los datos excluyen un beneficio de la dosis alta, aunque no precisan la magnitud del daño.

Palabras clave: tablas de contingencia; pruebas exactas incondicionales; test de Boschloo; potencia estadística; ensayos clínicos pequeños; ética de la investigación.

1. Introducción

Un valor p no mide la probabilidad de que una hipótesis sea cierta. Mide cuán compatibles son los datos observados con un modelo nulo, dentro de un modelo estadístico especificado de antemano. La declaración de la American Statistical Association lo resumió en tres palabras —contexto, proceso y propósito— (**WassersteinLazar2016**), y el llamado posterior a ir más allá de $p < 0{,}05$ (**WassersteinSchirmLazar2019**) insiste en lo mismo. En las tablas de contingencia pequeñas la advertencia pesa más: como las distribuciones son discretas, esa compatibilidad depende en buena medida del conjunto de tablas posibles que se decida considerar.

El test exacto de Fisher es el caso más visible de esa dependencia. Figura, junto con la prueba t y la ji cuadrado de Pearson, entre las pruebas más frecuentes en la literatura clínica (**Hellems2007**), y las guías de lectura crítica lo presentan como la prueba correcta para tablas 2×2 con muestras pequeñas (**duPrel2010**). La recomendación desciende de una regla práctica antigua: cuando alguna frecuencia esperada es menor que 5, la aproximación ji cuadrado se vuelve dudosa (**Cochran1954**), y Fisher aparece como la alternativa natural. La regla responde bien a una pregunta —cuándo deja de ser fiable la aproximación asintótica—, pero no a otra anterior: qué cantidades de la tabla fijó el diseño.

La palabra “exacto” se presta a confusión. Sugiere que no hubo aproximaciones y que, por tanto, no queda nada por discutir. Pero la exactitud es una propiedad del cálculo, no de la pertinencia de la pregunta que ese cálculo responde. Tukey lo advirtió hace más de sesenta años: vale más una respuesta aproximada a la pregunta correcta que una respuesta exacta a la pregunta equivocada (**Tukey1962**). El test de Fisher construye su respuesta condicionando a los dos márgenes observados de la tabla. En los diseños en que el protocolo fija el tamaño de

los grupos pero deja al azar el número total de respuestas, ese condicionamiento sigue siendo válido; lo que ocurre es que la prueba puede resultar más conservadora que otra que aproveche la variabilidad de ese margen.

El recorrido que sigue examina el condicionamiento como una elección inferencial y no como un detalle técnico (Sección 2); describe las alternativas exactas disponibles (Sección 3); muestra en un ensayo clínico real cuán sensible puede ser la conclusión a esa elección y cuantifica, por enumeración exacta, cuánto de esa sensibilidad se sostiene fuera del caso particular (Sección 4); extiende la comparación a la estimación del efecto y a sus intervalos, donde el mismo conservadurismo toma la forma de un compromiso entre sesgo y varianza (Sección 5); ofrece algunas hipótesis sobre el uso habitual de Fisher (Sección 6), y propone una práctica de análisis más explícita, con sus implicaciones éticas (Sección 7). No se trata de declarar obsoleto un procedimiento útil, sino de sostener que su uso debe desprenderse del diseño y de la pregunta del estudio.

2. El condicionamiento como elección de modelo

Para ver por qué condicionar es una elección y no un hecho, conviene fijar la notación. Consideremos dos grupos de tamaños n_1 y n_2 y un desenlace binario. Sean X_{ij} las frecuencias observadas, con $i = 1, 2$ para la fila (el grupo) y $j = 1, 2$ para la columna (el desenlace); $X_{i+} = n_i$ son los totales de fila y X_{+j} los de columna. Bajo la hipótesis nula de igualdad de las probabilidades de respuesta, $H_0 : p_1 = p_2 = p$, el valor común p es un parámetro de estorbo (*nuisance*): no interesa en sí mismo, pero hay que eliminarlo para construir la prueba.

Fisher lo elimina condicionando a todos los márgenes. Dados

n_1, n_2 y X_{+1}, la celda X_{11} sigue bajo H_0 una distribución hipergeométrica, que ya no depende de p. La construcción es elegante y garantiza que el error tipo I nunca supere el nivel nominal.

El costo aparece cuando el margen de respuestas es aleatorio. Condicionar a su valor observado restringe el análisis a las tablas con el mismo total de éxitos, una cantidad que en un ensayo comparativo típico no fijó el protocolo. La prueba sigue siendo válida en sentido frecuentista, pero suele ser conservadora: como la hipergeométrica es discreta, rara vez puede usar todo el nivel α, y lo que no se usa se paga con una probabilidad de error tipo II mayor que la necesaria. En estudios pequeños, donde la potencia ya es escasa, ese conservadurismo adicional puede salir caro. No es un defecto del cálculo, sino el precio de garantizar el nivel dentro de cada valor posible del margen, y no solo en promedio sobre todos ellos.

La pregunta de fondo, entonces, no es si Fisher es válido, sino a qué pregunta responde y si es la que el estudio formuló. Hay al menos una lectura en la que el condicionamiento deja de ser una imposición. En un ensayo aleatorizado puede razonarse desde el sorteo mismo (**Fisher1935**): bajo la hipótesis nula estricta de que el tratamiento no cambió el desenlace de ningún participante, el total de respuestas queda fijado por la propia hipótesis, y lo único aleatorio es cómo la asignación repartió esas respuestas entre los grupos. Ese reparto es hipergeométrico, y el test de Fisher es entonces exactamente la prueba de aleatorización del ensayo (**Rosenbaum2002**). La discusión sobre si el margen de respuestas debe tratarse como fijo es, además, antigua y no está zanjada: **Yates1984** defendió el condicionamiento con argumentos de ancilaridad aproximada, y su artículo se publicó con una discusión extensa que recoge las objeciones.

Lo que esa lectura deja claro es que la tabla, por sí sola, no elige el modelo. La inferencia por aleatorización pregunta por los participantes del estudio: si el tratamiento cambió el desenlace de alguno de ellos. El modelo de dos binomiales indepen-

dientes, $X_1 \sim \text{Bin}(n_1, p_1)$ y $X_2 \sim \text{Bin}(n_2, p_2)$, pregunta por la población de la que provienen: si la probabilidad de respuesta difiere entre tratamientos. La segunda es la que suele interesar a una guía clínica y la que, de ordinario, supone el cálculo del tamaño muestral. En datos transversales u observacionales, donde no se fijó ningún margen, condicionar a ambos totales descarta todavía más información. En lo que sigue se adopta el modelo de dos binomiales, que es aquel en el que Fisher y las alternativas de la sección siguiente pueden compararse en los mismos términos; la vía de la aleatorización queda reconocida, pero fuera del alcance de los cálculos.

3. Alternativas exactas

Si el diseño indica que el margen de respuestas no debe condicionarse, la inferencia puede seguir siendo exacta sin hacerlo. Las alternativas incondicionales comparten una idea: tratar como aleatorio todo lo que es aleatorio, eliminar el parámetro nuisance maximizando o integrando sobre él, y garantizar el control del error tipo I para cualquier valor que ese parámetro pueda tomar. **FayProschanBrittain2014** ofrecen una perspectiva moderna sobre cómo construir inferencias exactas compatibles con ambos enfoques.

3.1. Barnard–CSM

Barnard1945; **Barnard1947** propuso conservar el cálculo exacto sin condicionar al margen de respuestas. Aquí, "Barnard" designa específicamente el procedimiento Barnard–CSM (*Convexity, Symmetry and Minimization*) de 1947, no todas las pruebas incondicionales que a veces reciben ese nombre. La lógica es la siguiente: para cada valor posible de p bajo H_0 se calcula la probabilidad de obtener una tabla al menos tan extrema como

la observada, y luego se toma el máximo sobre p. El valor p incondicional es, así, el peor caso frente al parámetro desconocido.

La prueba tuvo dos dificultades históricas. La primera era conceptual: ¿qué significa "más extrema" cuando la distribución ya no es hipergeométrica? Hace falta un ordenamiento de las tablas. La segunda era práctica: la maximización sobre p resultaba demasiado costosa para los medios de cálculo de la época. Los refinamientos posteriores y el software actual resolvieron la segunda; la primera persiste, porque el ordenamiento sigue siendo una decisión que el investigador debe justificar.

3.2. Boschloo

Boschloo1970 encontró una salida elegante al problema del ordenamiento: usar el propio valor p de Fisher como criterio para ordenar las tablas dentro de una prueba incondicional. La consecuencia puede verse en una línea. Sea P_F el valor p de Fisher, considerado como estadístico. Por ser un valor p condicional válido, cumple $\Pr(P_F \le u \mid X_{+1} = m) \le u$ para cada margen m; promediando sobre la distribución del margen, $\Pr_p(P_F \le u) \le u$ para todo p. El valor p de Boschloo de una tabla con $P_F = u$ es el supremo de esa probabilidad sobre p, de modo que nunca supera a u:

$$P_B \;=\; \sup_{p} \Pr_{p}(P_F \le u) \;\le\; u \;=\; P_F.$$

Toda tabla que Fisher rechaza, Boschloo también la rechaza ($R_F \subseteq R_B$), y la potencia de Boschloo es al menos la de Fisher para cualquier (p_1, p_2). El argumento vale para cada definición del valor p bilateral, siempre que ambas pruebas usen la misma (Sección 4.3), y no se pierde si el supremo se calcula sobre una malla, porque una malla solo puede subestimarlo. Lo que la desigualdad no dice es cuánto se gana;

eso depende del diseño y del escenario, y es lo que la Sección 4 cuantifica. La garantía, junto con su facilidad de cálculo, explica que Boschloo figure entre las recomendaciones principales para comparar dos proporciones en muestras pequeñas (**LydersenFagerlandLaake2009**).

3.3. Suissa–Shuster

Boschloo resuelve el ordenamiento; queda una cuestión anterior al análisis: el tamaño de la muestra. **SuissaShuster1985** desarrollaron una prueba incondicional basada en el estadístico z y los cálculos de tamaño muestral correspondientes para el ensayo binomial 2×2. Su trabajo mostró que, si un estudio se planifica bajo el modelo de dos binomiales, analizarlo después con una prueba condicional puede contradecir los supuestos con que se calculó su tamaño. La coherencia entre diseño y análisis vuelve a ser el eje del argumento.

3.4. Berger–Boos

BergerBoos1994 mostraron que no hace falta maximizar sobre todo el rango del parámetro nuisance: basta con hacerlo sobre un intervalo de confianza para p con cobertura $1 - \gamma$ y sumar γ al valor p resultante como penalización. **LydersenLangaasBakke2012** estudiaron la elección de γ para la prueba incondicional z con varianza combinada y encontraron que $\gamma = 10^{-4}$ era óptimo o casi óptimo en los escenarios que evaluaron. Con un γ pequeño la penalización apenas agrega conservadurismo y la ganancia de potencia puede ser apreciable. El procedimiento conserva el control del error tipo I; cuánto reduce el conservadurismo de la maximización completa depende de la construcción y del valor de γ.

3.5. Mid-p

El mid-p no es una prueba incondicional, sino una corrección del carácter discreto de las pruebas exactas. En lugar de sumar la probabilidad completa de las tablas al menos tan extremas como la observada, suma la de las estrictamente más extremas y solo la mitad de la probabilidad de la observada. Cambia la garantía puntual sobre el nivel por un mejor comportamiento promedio: su tamaño puede exceder ligeramente α en algunos valores del parámetro nuisance, aunque en las tablas 2×2 suele quedar cerca. **LydersenFagerlandLaake2009** lo incluyen, en la versión mid-p del test de Fisher, entre sus recomendaciones para tablas pequeñas, y **FagerlandLydersenLaake2013** llegan a una conclusión análoga para la prueba de McNemar.

3.6. Integrar en lugar de maximizar: el m-test

Una propuesta más reciente es el *m-test* de **AraujoVocesQuesada2021**. En vez de maximizar sobre el parámetro nuisance o estimarlo, integra sobre todos sus valores posibles, de modo que no depende de un valor concreto de p bajo H_0. Las simulaciones de sus autores sugieren que puede ser más potente que Barnard–CSM o Boschloo en tablas pequeñas, aunque todavía está poco disponible en el software de uso corriente.

3.7. Resumen comparativo

La Tabla 1 reúne las características principales de cada procedimiento. Ninguno es mejor en todos los escenarios: la elección depende del diseño, del parámetro de interés, de la hipótesis y del equilibrio que se acepte entre control exacto del error tipo I y potencia. La columna del valor p bilateral merece atención: la definición `minlike` suma las probabilidades de las tablas no más probables que la observada, y la `central` duplica la cola

menor. No es un detalle de presentación, porque en las pruebas que ordenan las tablas mediante un valor p previo puede cambiar la decisión.

4. Ilustración: epinefrina en paro cardíaco pediátrico

El ensayo de **Perondi2004** —prospectivo, aleatorizado y doble ciego— asignó 68 niños con paro cardíaco intrahospitalario que no habían respondido a una dosis inicial estándar a recibir una segunda dosis, estándar o alta, de epinefrina; el desenlace primario fue la supervivencia a 24 horas. Sobrevivieron 7 de 34 niños con la dosis estándar y 1 de 34 con la dosis alta. La Tabla 2 muestra lo que dicen tres procedimientos sobre esa misma tabla.

Con el umbral convencional de 0,05, la elección del procedimiento cambia el veredicto: Fisher no rechaza la hipótesis nula; Boschloo y Barnard–CSM, sí. En esta tabla, además, las dos definiciones bilaterales que ofrece `exact2x2` coinciden: con `tsmethod="minlike"` (suma de las probabilidades de las tablas no más probables que la observada) y con `tsmethod="central"` (el doble de la cola menor), Boschloo da 0,0385, porque con $n_1 = n_2$ la región bilateral es la unión de dos colas simétricas. El valor coincide con el de `Exact` (0,03846) y no cambia al refinar la malla del parámetro nuisance.

Dos detalles de cálculo merecen declararse, porque cambian el resultado. El primero es la maximización. Vista como función del parámetro nuisance, la probabilidad de la cola de Boschloo tiene tres máximos locales: 0,0282 en $p \approx 0{,}134$ y en $p \approx 0{,}866$, y 0,0385 en $p = 0{,}5$, que es el máximo global. Una maximización que se detiene en el primer pico reporta 0,028 en lugar de 0,0385. El segundo es la orientación de la tabla.

Tabla 1: Procedimientos para tablas 2×2. Cuando una prueba ordena las tablas mediante un valor p previo, la definición bilateral modifica el propio ordenamiento (Sección 4.3).

Prueba	Modelo	Ordenamiento	Valor p bilateral	Propiedad
Fisher exacto	Condicional (ambos márgenes)	Probabilidad hipergeométrica	`minlike` o `central`	Control exacto del nivel; conservador
Boschloo	Incondicional (dos binomiales)	Valor p de Fisher	Hereda la de Fisher, que redefine el orden	Al menos tan potente como Fisher ($P_B \leq P_F$)
Barnard–CSM	Incondicional	Convexity, Symmetry, Minimization	Según implementación	Potente; exige justificar el ordenamiento
Suissa–Shuster	Incondicional	Estadístico z (varianza combinada)	Simétrico en $\lvert z \rvert$	Tamaño muestral y análisis bajo el mismo modelo
Berger–Boos	Incondicional	El del estadístico; máximo sobre un IC	Hereda la del estadístico	Menos conservadora que la maximización completa
Mid-p	Corrección del carácter discreto	Hipergeométrica; media probabilidad a la observada	Hereda la de Fisher	Mejor potencia promedio; pierde control puntual
m-test	Incondicional	Integra sobre p	Según implementación	Potencia prometedora; poco software disponible

Tabla 2: Valores p bilaterales para el ensayo de **Perondi2004** (7/34 frente a 1/34).

Procedimiento	Implementación	Valor p
Fisher exacto	`fisher.test`	0,0544
Boschloo	`exact2x2::boschloo`	0,0385
Barnard–CSM	`Exact::exact.test`	0,0279

`Exact::exact.test` supone por defecto que los totales fijos son los de fila (`cond.row = TRUE`); si recibe la tabla con los grupos en columnas, fija los totales de sobrevivientes y fallecidos en lugar de los tamaños de grupo, y el valor de CSM baja a 0,0244 sin que el programa lo advierta. En ambos casos el software entrega un número plausible que responde a otra pregunta. Bien orientada la tabla, CSM y la prueba incondicional basada en el estadístico z, con o sin varianza combinada, casi coinciden (0,0279 y 0,0281): en esta tabla pesa más la orientación que el ordenamiento.

Ninguno de esos valores p mide por sí solo la magnitud ni la importancia clínica del efecto, de modo que el estimando también debe declararse. La supervivencia fue mayor con la dosis estándar: la diferencia de riesgos observada es $\hat{p}_1 - \hat{p}_2 = 6/34 \approx 0{,}176$, la razón de riesgos es 7 y la razón de odds, $\approx 8{,}6$. Los intervalos de confianza correspondientes no son intercambiables: un intervalo compatible con Fisher (condicional) no coincide, en general, con uno compatible con un procedimiento incondicional, por lo que el estimando y su intervalo deben reportarse junto con la prueba elegida. Cada prueba responde a una construcción inferencial distinta: Fisher condiciona a los márgenes observados, mientras que Boschloo y Barnard trabajan bajo el modelo de dos binomiales independientes. Si el protocolo fijó el tamaño de los grupos, pero no el número total de sobrevivientes, este último modelo parece más coherente con el diseño. Fisher sigue siendo válido como análisis condicional, y es la prueba natural si la pregunta es la de la aleatorización

(Sección 2); como respuesta a la pregunta poblacional, en cambio, es innecesariamente conservador.

Ese conservadurismo admite una lectura que no depende del lenguaje frecuentista. **Altham1969** mostró que el valor p unilateral de Fisher coincide con una probabilidad posterior: la de que la asociación vaya en sentido contrario al observado, calculada con dos distribuciones a priori impropias muy particulares. En Perondi son una $\text{Beta}(0, 1)$ para la supervivencia con dosis estándar, que concentra su peso cerca de cero, y una $\text{Beta}(1, 0)$ para la dosis alta, que lo concentra cerca de uno. El valor p unilateral es 0,0272, y la probabilidad posterior de que la dosis alta sea mejor, con esas a priori, es también 0,0272; con a priori uniformes, $\text{Beta}(1, 1)$, esa probabilidad baja a 0,0138, la mitad. La equivalencia no convierte a Fisher en un procedimiento bayesiano, pero sí da contenido al adjetivo: la prudencia del test equivale a partir de una opinión previa inclinada en contra del efecto que los datos sugieren. En el análisis bayesiano, las opiniones previas se declaran.

El caso de Perondi no demuestra que la elección de Fisher haya cambiado alguna decisión clínica; afirmarlo exigiría reconstruir decisiones, protocolos y contextos que el artículo no reporta. Lo que sí muestra es que, en estudios pequeños con eventos raros, procedimientos inferenciales distintos pueden llevar a decisiones distintas frente al umbral $\alpha = 0{,}05$. Esa sensibilidad debería formar parte del informe, no quedar oculta tras un único valor p.

4.1. ¿Qué tan frecuente es la discrepancia?

Podría pensarse que la discrepancia de Perondi es un accidente de una sola tabla. Para averiguarlo se tomó como escenario de referencia dos grupos independientes de $n = 34$ con proporciones $p_1 = 0{,}20$ y $p_2 = 0{,}03$, cercanas a las observadas

($7/34 \approx 0{,}206$ y $1/34 \approx 0{,}029$), que se usan como valores de referencia y no como estimaciones de las probabilidades verdaderas. Con $n_1 = n_2 = 34$ solo existen $35 \times 35 = 1225$ tablas posibles, así que basta enumerarlas y ponderar cada una por su probabilidad binomial exacta bajo el escenario, $P(\text{rechazo}) = \sum_{x_1} \sum_{x_2} \mathrm{I}\{\text{rechazo}\}\, P(X_1 = x_1) P(X_2 = x_2)$. La misma enumeración se usó para los demás tamaños muestrales de la Figura 2. Un solo escenario no autoriza conclusiones generales; lo que ofrece es una indicación, que la Sección 4.2 somete a una familia amplia de escenarios.

La Tabla 3 resume el resultado. Fisher y Boschloo toman decisiones opuestas en tablas que acumulan el 11,6 % de la probabilidad del escenario, algo más de uno de cada nueve conjuntos de datos; Fisher y Barnard–CSM, en el 15,4 %; Boschloo y Barnard–CSM, en el 3,9 %. La tabla de Perondi está entre las discordantes. No es, por tanto, una rareza: pertenece a una clase de configuraciones que, bajo este escenario, aparece con frecuencia apreciable.

La discordancia entre Fisher y Boschloo tiene una sola dirección: ninguna de las 1225 tablas es rechazada por Fisher y no por Boschloo, mientras que 40 son rechazadas por Boschloo y no por Fisher. Si R denota la región de rechazo de cada procedimiento, la enumeración confirma $R_F \subseteq R_B$, como exige la desigualdad $P_B \leq P_F$ de la Sección 3.2; que se cumpla en las 1225 tablas es, sobre todo, una verificación de la implementación. Para CSM no hay una garantía análoga y, sin embargo, ocurre lo mismo: 40 tablas rechazadas por CSM y no por Fisher, ninguna en sentido inverso, de modo que $R_F \subseteq R_{CSM}$ en esta configuración. Entre Boschloo y CSM, en cambio, no hay inclusión en ningún sentido: 16 tablas son rechazadas solo por Boschloo y otras 16 solo por CSM. Esto se reporta para esta configuración y no como propiedad general; indica que ambos procedimientos ordenan el espacio muestral de maneras genuinamente distintas.

Tabla 3: Discordancia exacta entre procedimientos sobre las 1225 tablas posibles con $n_1 = n_2 = 34$ y $\alpha = 0{,}05$, ponderada por su probabilidad binomial bajo $p_1 = 0{,}20$, $p_2 = 0{,}03$. "Tablas discordantes" cuenta las celdas de la rejilla en las que las decisiones difieren; la probabilidad reportada es la masa conjunta de esas celdas bajo el escenario.

Comparación	Tablas discordantes	Probabilidad exacta	Dirección
Fisher vs. Boschloo	40	11,6 %	Unidireccional: $R_F \subseteq R_B$
Fisher vs. Barnard–CSM	40	15,4 %	Unidireccional: $R_F \subseteq R_{CSM}$
Boschloo vs. Barnard–CSM	32	3,9 %	Bidireccional: 16 tablas en cada sentido

El mapa de la Figura 1 permite ver dónde ocurre el fenómeno. Cada celda representa una tabla posible con 34 observaciones por grupo. La franja naranja reúne las tablas en las que Fisher no rechaza y Boschloo sí; la región "Fisher sí, Boschloo no" está vacía. La tabla observada de Perondi, con $x_1 = 7$ y $x_2 = 1$, cae precisamente en esa franja.

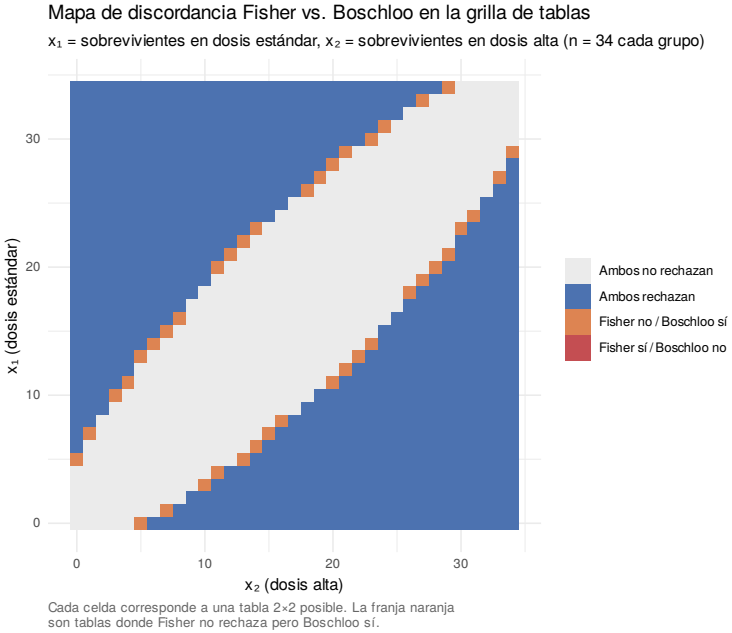


Figura 1: Regiones de decisión de Fisher y Boschloo en las 1225 tablas posibles con $n_1 = n_2 = 34$. La franja naranja identifica las tablas que Boschloo declara significativas y Fisher no.

Bajo el mismo escenario, la probabilidad exacta de rechazo fue 43,3 % con Fisher, 54,9 % con Boschloo y 58,7 % con Barnard–CSM. Como las regiones de rechazo están anidadas, las diferencias de potencia coinciden con las discordancias de la Tabla 3: $54{,}9 - 43{,}3 = 11{,}6$ y $58{,}7 - 43{,}3 = 15{,}4$ puntos porcentuales. Bajo H_0, el tamaño máximo, evaluado sobre una malla de 1999 valores de p, fue 0,0305 para Fisher, 0,0466 para Boschloo y 0,0475 para CSM: Fisher deja sin usar cerca del 40 % del nivel nominal, mientras que Boschloo y CSM lo respetan aprovechándolo casi por completo. Estas cifras describen el escenario y los procedimientos, no a cada prueba en abstracto: la potencia es función de n_1, n_2, p_1, p_2, α y del procedimiento. La enumeración tampoco prueba que la diferencia observada en Perondi sea real, ni autoriza a escoger, después de ver los datos, el valor p más pequeño. Lo que muestra es que, cuando el estudio es pequeño y los eventos escasos, la elección del procedimiento cambia de manera tangible la probabilidad de detectar un efecto.

La Figura 2 muestra que esa sensibilidad no se desvanece de manera suave al aumentar n. En el escenario considerado, la discordancia pasa de 13,2 % con $n = 15$ a 3,9 % con $n = 20$, vuelve a 12,8 % con $n = 30$ y baja a 4,5 % con $n = 60$. Las oscilaciones son esperables en pruebas discretas: al cambiar el tamaño muestral cambian también los valores críticos disponibles, y la discordancia puede subir antes de bajar. En todos los tamaños evaluados, de 10 a 60, la inclusión $R_F \subseteq R_B$ se mantiene, como debía; lo que oscila no es el sentido de la diferencia, sino su magnitud. Por eso la planificación debería comparar los procedimientos bajo varios tamaños y escenarios plausibles, en lugar de suponer que todos tienen la misma potencia.

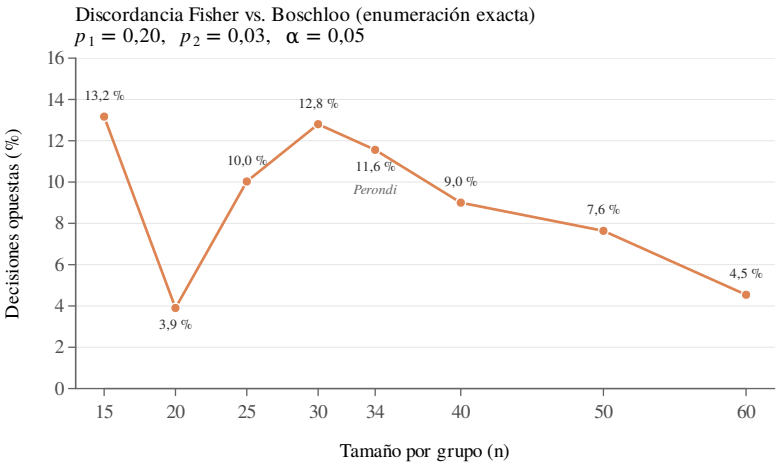


Figura 2: Probabilidad de que Fisher y Boschloo tomen decisiones opuestas, en función del tamaño por grupo, bajo $p_1 = 0{,}20$, $p_2 = 0{,}03$ y $\alpha = 0{,}05$, por enumeración exacta. Las oscilaciones reflejan el carácter discreto de las reglas de decisión.

4.2. Más allá de un escenario

Las cifras anteriores dependen de un punto: $p_1 = 0{,}20$, $p_2 = 0{,}03$, $n = 34$. Para saber cuánto de lo observado se sostiene fuera de él conviene aprovechar una propiedad sencilla de la enumeración: la región de rechazo de cada procedimiento depende solo de n_1, n_2 y α, no de las probabilidades verdaderas. Una vez calculada, la potencia bajo cualquier par (p_1, p_2) es una suma ponderada sobre la misma región. Así se obtuvieron la potencia de Fisher y de Boschloo sobre una rejilla de $p_1 > p_2$ entre 0,01 y 0,60, con paso 0,01, para cuatro diseños balanceados, y el tamaño de ambas pruebas bajo H_0 para todos los tamaños entre 10 y 60 por grupo.

La Figura 3 y la Tabla 4 resumen el resultado. Que la ganancia no sea negativa estaba garantizado de antemano (Sección 3.2); lo que la enumeración añade es su forma, y tres rasgos se repiten en los cuatro diseños. Primero, la ganancia fue estrictamente positiva en todos los puntos de la rejilla, aunque en algunos ínfima. Segundo, se concentra donde uno de los grupos tiene eventos muy raros: en los cuatro diseños, el máximo se alcanzó en $p_2 = 0{,}01$, el borde de la rejilla. Es la situación de Perondi y, en general, la de los ensayos pequeños con un desenlace infrecuente en uno de los brazos. Tercero, la ganancia disminuye al crecer n, pero no desaparece en el rango estudiado: con 50 por grupo, el 55 % de los escenarios de la zona informativa muestra todavía una diferencia de al menos 5 puntos porcentuales.

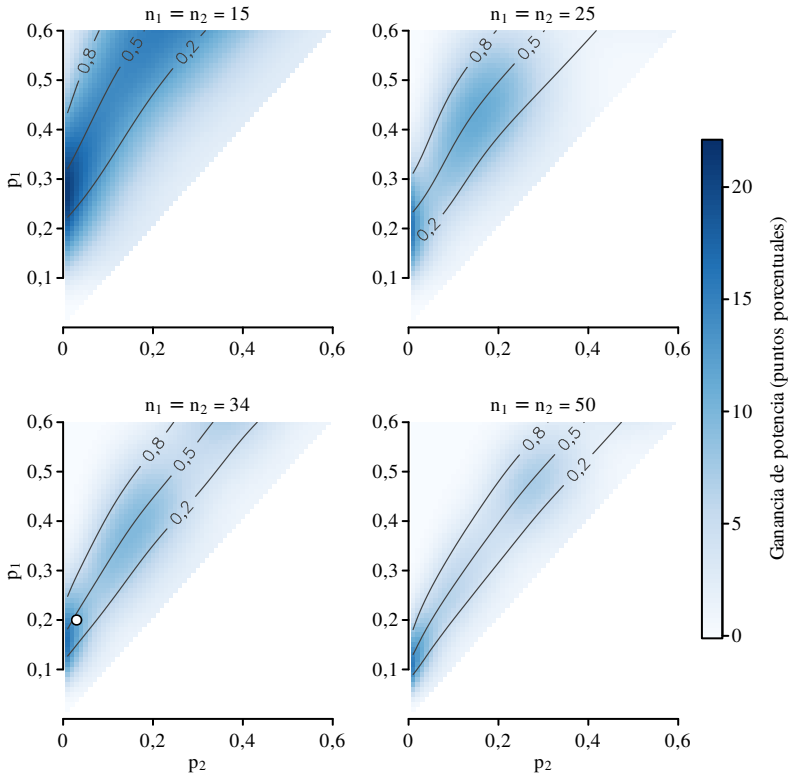


Figura 3: Ganancia exacta de potencia de Boschloo sobre Fisher (puntos porcentuales) para $p_1 > p_2$, $\alpha = 0{,}05$ y cuatro diseños balanceados. Las curvas indican la potencia de Fisher (0,2, 0,5 y 0,8). El punto blanco marca el escenario de referencia de la Sección 4.1.

Tabla 4: Ganancia exacta de potencia de Boschloo sobre Fisher, en puntos porcentuales, sobre la rejilla $0{,}01 \leq p_2 < p_1 \leq 0{,}60$. La zona informativa reúne los escenarios en que Fisher tiene potencia entre 0,2 y 0,8; P10 y P90 son sus percentiles 10 y 90.

n por grupo	Mediana (zona inf.)	P10–P90 (zona inf.)	≥ 5 pts. (zona inf.)	Máximo (rejilla)	Tamaño máx. de Fisher
15	13,9	11,5–16,4	100 %	21,1	0,018
25	8,0	3,7–10,7	83 %	15,4	0,033
34	7,0	4,9–9,4	88 %	16,4	0,031
50	5,1	3,1–7,1	55 %	15,2	0,035

El origen de la ganancia se ve en la Figura 4. Bajo H_0, la probabilidad de rechazo de Fisher queda muy por debajo del nivel nominal en todo el rango de p: con 15 por grupo no supera 0,018, y en ninguno de los tamaños entre 15 y 50 supera 0,038. El tamaño máximo de Boschloo, en cambio, estuvo entre 0,041 y 0,0497 en esos mismos tamaños, sin exceder nunca α. La diferencia de potencia es, en buena parte, nivel nominal que Fisher no usa: no una protección adicional que alguien haya elegido, sino un margen que la discreción de la hipergeométrica deja sin asignar.

La prueba z con varianza combinada de Suissa–Shuster, maximizada sobre el parámetro nuisance de la misma manera, prolonga la secuencia. En los cinco diseños balanceados en que se comparó con Boschloo (15, 20, 25, 34 y 50 por grupo), su región de rechazo contuvo a la de Boschloo: coincidieron con 15 por grupo, y en los demás la prueba z rechazó entre 4 y 12 tablas adicionales. En el escenario de referencia su potencia fue de 60,8 %, con un tamaño máximo de 0,0467. En esos diseños se observa, por tanto, una cadena $R_F \subseteq R_B \subseteq R_z$, cuyo primer eslabón está garantizado y cuyo segundo es solo empírico; no se examinó si se mantiene en otros diseños ni en otros niveles.

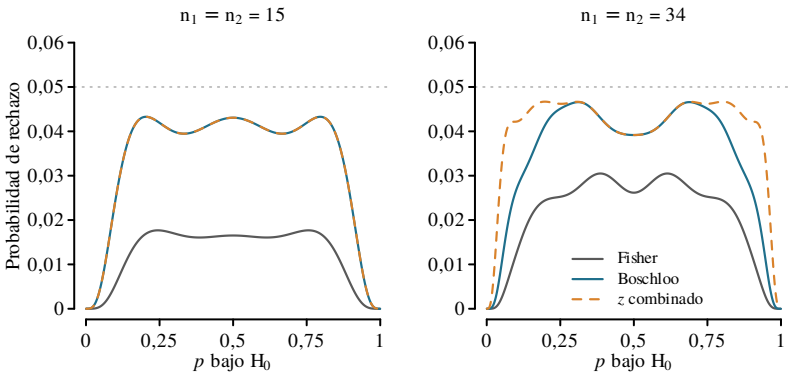


Figura 4: Probabilidad exacta de rechazo bajo $H_0 : p_1 = p_2 = p$ para $\alpha = 0{,}05$ (línea punteada). Con 15 por grupo, las regiones de Boschloo y de la prueba z coinciden.

4.3. La definición bilateral no es neutral

En Perondi, las definiciones `minlike` y `central` coinciden porque los grupos son del mismo tamaño. En diseños desbalanceados dejan de coincidir, y como Boschloo usa el valor p de Fisher para ordenar las tablas, la definición elegida cambia el ordenamiento mismo y no solo el valor final. Con 10 participantes en un grupo y 30 en el otro, por ejemplo, la tabla 2/10 frente a 0/30 tiene un valor p de Fisher de 0,058 con `minlike` y de 0,115 con `central`; el de Boschloo es 0,035 con la primera definición y 0,059 con la segunda, calculada como en `exact2x2`: el doble del menor de los dos valores p unilaterales de Boschloo. La tabla 2/10 frente a 17/30 muestra el efecto contrario: Boschloo da 0,054 con `minlike` y 0,048 con `central`. En ese diseño, 8 de las 341 tablas posibles cambian de decisión según la definición, en uno y otro sentido; en los diseños 15 frente a 45 y 20 frente a 40 cambian 12 y 6. Ninguna definición domina a la otra. La elección, por tanto, debe declararse antes del análisis, con la misma seriedad que la elección de la prueba. En los tres diseños desbalanceados, y para cada definición, la región de

rechazo de Fisher siguió contenida en la de Boschloo, como garantiza la desigualdad de la Sección 3.2: la definición bilateral cambia qué tablas gana Boschloo, no el hecho de que gane.

4.4. Alcance y reproducibilidad

Estos cálculos amplían la ilustración, pero no la convierten en un estudio general. Se limitan a $\alpha = 0{,}05$, a diseños mayoritariamente balanceados y, en la superficie de potencia, a la comparación entre Fisher, Boschloo y la prueba z. Barnard–CSM, Berger–Boos y el m-test quedaron fuera de ella, aunque Berger–Boos y el mid-p se examinan, para $n_1 = n_2 = 34$, en la Sección 5. Una evaluación completa debería extenderse a otros niveles, a una gama más amplia de desbalances y a la probabilidad de discordancia como función conjunta de n, p_1, p_2 y del balance entre grupos.

Todas las cifras, tablas y figuras de las Secciones 4 a 4.3 se obtienen con un solo guion de R 4.3.3 (`simulacion3.R`). Fisher se calculó con `fisher.test`; Boschloo, con `exact2x2` 1.7.0; Barnard–CSM y la prueba z, con `Exact` 3.3, con los grupos en filas (`cond.row = TRUE`). La potencia de CSM obtenida por enumeración coincide con la de `Exact::power.exact.test` (0,5874). Para los barridos sobre n y sobre (p_1, p_2), el guion aplica directamente la definición de Boschloo: el máximo, sobre una malla de 10 001 valores del parámetro nuisance, de la cola ordenada por el valor p de Fisher, con una tolerancia relativa de 10^{-7} para los empates, la misma de `fisher.test`. En $n = 34$ esa implementación reproduce las 1225 decisiones de `exact2x2`; los valores p difieren en algunas tablas en menos de 0,003, por el tratamiento de empates en coma flotante, sin que cambie ninguna decisión. La equivalencia de Altham se calculó por integración numérica con `integrate`. Registrar estos parámetros no es un formalismo: los valores p de los procedimientos incondicionales dependen del ordenamiento,

de la definición bilateral, de la maximización, del tratamiento de los empates y de la orientación con que se entrega la tabla.

5. Calibración, estimación y el compromiso entre sesgo y varianza

Las secciones anteriores compararon decisiones. Un informe clínico, sin embargo, no termina en la decisión: estima un efecto y le asigna un intervalo, y en esos dos pasos reaparece, con otra forma, el mismo intercambio. La descomposición del error cuadrático medio (ECM) en sesgo y varianza pertenece a la teoría de la estimación (**Geman1992**): un estimador puede aceptar un sesgo pequeño a cambio de una reducción mayor de su varianza. Una prueba no estima nada y la descomposición no se le aplica tal cual, pero tiene un análogo directo: garantizar que el error tipo I no supere α se paga con potencia. Esta sección mide ese intercambio en tres planos —el contraste, el estimador y el intervalo— con la misma enumeración de las 1225 tablas de Perondi; cada esperanza es una suma finita sobre ellas, sin error de simulación.

Se conserva la orientación de la Sección 4: el grupo 1 recibió la dosis estándar ($x_1 = 7$) y el grupo 2 la dosis alta ($x_2 = 1$). El efecto se expresa como logaritmo de la razón de odds, $\theta = \log \mathrm{OR} = \operatorname{logit} p_1 - \operatorname{logit} p_2$, o como diferencia de riesgos, $\Delta = p_1 - p_2$; valores positivos indican mayor supervivencia con la dosis estándar.

5.1. En el contraste: calibración frente a potencia

La Sección 4.2 mostró que Fisher deja sin usar cerca del 40 % del nivel nominal. Para saber cuánta potencia cuesta eso se añade una prueba de referencia: la versión aleatorizada de Fisher

(**Tocher1950**), que en la tabla frontera rechaza con una probabilidad intermedia, elegida para que el tamaño condicional sea exactamente α en cada margen (**LehmannRomano2005**). Nadie la usaría en un ensayo, porque su veredicto dependería de un sorteo ajeno a los datos. Sirve de patrón: indica cuánta potencia tendría Fisher si la discreción no le costara nada.

La Tabla 5 usa dos medidas de potencia. La *potencia media* promedia la probabilidad de rechazo, de forma uniforme, sobre una región clínicamente plausible: $0{,}15 \le p_1 \le 0{,}35$ para la dosis estándar y $p_2 \le 0{,}10$ para la alta. La *potencia predictiva* la promedia sobre la distribución posterior de (p_1, p_2) dados los datos, con a priori de Jeffreys en cada brazo, y responde a otra pregunta: con lo que este ensayo enseñó, qué probabilidad tendría una réplica del mismo tamaño de rechazar H_0 (**OHagan2005**). No es la "potencia observada" que critican **HoenigHeisey2001**, porque no sustituye las proporciones verdaderas por las estimadas: promedia sobre la incertidumbre que queda sobre ellas. En la tabla, el tamaño se evalúa sobre 1999 valores de p bajo H_0; la prueba z es la de varianza combinada de Suissa–Shuster, y Berger–Boos usa $\gamma = 0{,}001$.

Tabla 5: Calibración y potencia exactas ($n_1 = n_2 = 34$, $\alpha = 0{,}05$).

Procedimiento	p en Perondi	Tamaño máximo	Tamaño medio	Potencia media	Potencia predictiva
Fisher	0,0544	0,0305	0,0213	0,515	0,438
Boschloo	0,0385	0,0466	0,0351	0,589	0,520
Berger–Boos	0,0314	0,0466	0,0351	0,589	0,520
Mid-p	0,0297	0,0467	0,0371	0,613	0,539
Prueba z	0,0281	0,0467	0,0404	0,628	0,570
Fisher aleatorizado	—	0,0500	0,0486	0,627	0,568

La versión aleatorizada pasa de una potencia media de 0,515 a 0,627: once puntos que Fisher pierde solo por la discreción de la hipergeométrica. La prueba z los recupera por completo y Bos-

chloo casi todos, sin sortear nada y sin que su tamaño supere α. El mid-p, que en general no garantiza el nivel (Sección 3), no lo superó en este diseño; el resultado vale para $n_1 = n_2 = 34$ y no se generaliza aquí. Berger–Boos reporta un valor p menor que Boschloo (0,031 frente a 0,038), pero toma exactamente las mismas decisiones en las 1225 tablas: cambia la evidencia que se informa, no la regla.

La potencia predictiva pone el conjunto en proporción. Aun con el mejor procedimiento no llega a 0,6: una réplica de Perondi con 34 niños por grupo tendría, con lo que hoy se sabe, poco más de la mitad de probabilidad de resultar concluyente. El procedimiento mueve esa probabilidad en unos trece puntos; el tamaño del ensayo la limita mucho más.

5.2. En la estimación: sesgo, varianza y ECM

La razón de odds observada es $7 \times 33/(27 \times 1) \approx 8{,}56$. Su logaritmo, el estimador de máxima verosimilitud (EMV) de θ, es infinito siempre que alguna celda valga cero, y bajo las proporciones observadas eso ocurre con probabilidad 0,363: prácticamente la de que ningún niño del grupo de dosis alta sobreviva, $(33/34)^{34} \approx 0{,}362$. El EMV no tiene, por tanto, sesgo ni varianza definidos, y lo mismo ocurre con el EMV condicional a los márgenes (EMVC, 8,33), que diverge en las mismas tablas. Para estimar hay que regularizar, y la forma más simple es sumar una constante c a cada celda,

$$\hat{\theta}_c = \log \frac{(x_1 + c)(n_2 - x_2 + c)}{(n_1 - x_1 + c)(x_2 + c)}.$$

Con $c = \tfrac{1}{2}$ se obtiene el estimador de Haldane–Anscombe (**Haldane1956**; **Anscombe1956**), que elimina el sesgo de primer orden del logit (**GartZweifel1967**) y que, en una tabla 2×2, coincide con la regresión logística penalizada de **Firth1993**.

Con los mismos datos, la elección del estimador mueve la razón de odds casi en un factor dos: 8,56 (EMV), 8,33 (EMVC), 6,71 ($c = \frac{1}{3}$), 6,09 ($c = \frac{1}{2}$) y 4,86 ($c = 1$). La Tabla 6 muestra por qué. Sus tres primeras columnas se evalúan en las proporciones observadas $(\hat{p}_1, \hat{p}_2)$; la última promedia el ECM sobre la posterior, que es el modo de no tratar como verdaderas unas proporciones que solo se estimaron.

Tabla 6: Sesgo, varianza y ECM exactos de estimadores de θ y de Δ.

Estimador	Sesgo	Varianza	ECM	ECM posterior
Logaritmo de la razón de odds, θ				
$\hat{\theta}_{1/3}$	0,023	0,975	0,975	0,950
$\hat{\theta}_{1/2}$ (Haldane; Firth)	−0,160	0,727	0,752	0,877
$\hat{\theta}_1$	−0,493	0,427	0,671	1,010
Media post. de θ (Jeffreys)	0,415	1,660	1,832	1,462
Diferencia de riesgos, Δ (varianza y ECM $\times 10^3$)				
EMV, $\hat{p}_1 - \hat{p}_2$	0,000	5,65	5,65	5,99
Agresti–Caffo	−0,010	5,04	5,13	5,46
Media post. (Jeffreys)	−0,005	5,33	5,36	5,69

En $(\hat{p}_1, \hat{p}_2)$ el compromiso se ve con nitidez (Figura 5). Con $c = \frac{1}{3}$ el sesgo es casi nulo, pero la varianza es la mayor; con $c = 1$ la varianza baja a menos de la mitad, pero el sesgo de $-0{,}49$ en escala logarítmica equivale a encoger la razón de odds en un factor cercano a $e^{-0{,}49} \approx 0{,}61$. El ECM evaluado en ese punto es mínimo en $c \approx 0{,}80$. Esa recomendación, sin embargo, usa los datos dos veces: elige la corrección óptima para unas proporciones que son, ellas mismas, una estimación. Cuando el ECM se promedia sobre la posterior, el óptimo se desplaza a $c \approx 0{,}55$, y el ECM con $c = \frac{1}{2}$ (0,877) difiere del mínimo (0,876) en la cuarta cifra. La corrección de Haldane, propuesta en 1956 con argumentos asintóticos, resulta prácticamente óptima en este diseño, y la corrección $c = 1$, que parecía la mejor en el punto estimado, pasa a ser la peor de las tres.

Un óptimo que depende del punto en que se evalúa no basta como recomendación. La media posterior de θ con a priori de Jeffreys, de la que podría esperarse un efecto regularizador, es el peor estimador de la tabla; el Apéndice A.2 explica por qué.

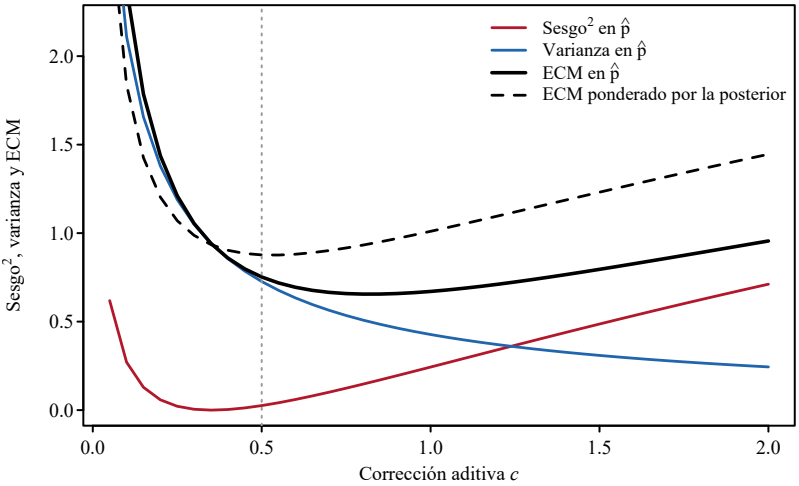


Figura 5: Sesgo al cuadrado, varianza y ECM de $\hat{\theta}_c$ en $(\hat{p}_1, \hat{p}_2)$, en función de la corrección aditiva c, y ECM promediado sobre la posterior (línea discontinua). La línea vertical marca $c = \frac{1}{2}$.

En la escala de la diferencia de riesgos el mismo compromiso existe, pero su peso clínico es mínimo. El EMV es insesgado; el estimador de **AgrestiCaffo2000** acepta un sesgo de un punto porcentual y reduce el ECM en un 9 %. En raíz del ECM, eso es pasar de 7,5 a 7,2 puntos porcentuales, y las estimaciones puntuales (0,176 y 0,167) difieren en menos de un punto. La fragilidad de la razón de odds no es, entonces, una propiedad de los datos, sino de la escala: con un brazo casi sin eventos, la razón de odds amplifica la incertidumbre del denominador y la diferencia de riesgos no.

5.3. En los intervalos: cobertura frente a longitud

El intercambio reaparece en los intervalos de confianza (IC) al 95 % para θ. El de **Woolf1955** con $c = \frac{1}{2}$ es siempre finito, pero su cobertura cae por debajo de 0,95 cuando los eventos del brazo de dosis alta se vuelven más raros: 0,953 con $(p_1, p_2) = (0{,}20;\ 0{,}03)$, 0,918 con $(0{,}20;\ 0{,}01)$. El exacto condicional de **Cornfield1956**, que es el que devuelve `fisher.test`, garantiza la cobertura, pero tiene longitud infinita con probabilidad 0,363 bajo las proporciones observadas, en las mismas tablas en que el EMV diverge (Apéndice A.3). Lo que uno gana en garantía lo paga el otro en información.

En la tabla de Perondi, los dos intervalos para la razón de odds incluyen el 1 por muy poco: [0,98; 37,7] con Woolf y [0,97; 396] con el exacto condicional, en concordancia con el $p = 0{,}054$ de Fisher. Los intervalos para la diferencia de riesgos lo excluyen: [0,012; 0,322] con Agresti–Caffo y [0,019; 0,340] con el método de **Newcombe1998**, en concordancia con las pruebas incondicionales. No hay contradicción. Son construcciones distintas —condicional o incondicional, en una escala o en otra—, y los datos están cerca de la frontera en todas ellas.

5.4. Lectura clínica

A las 24 horas sobrevivió el 20,6 % de los niños con dosis estándar y el 2,9 % con dosis alta. La diferencia de riesgos, 17,6 puntos porcentuales, equivale a un número necesario para dañar (NND, $1/\Delta$) de 5,7: por cada seis niños tratados con dosis alta en lugar de estándar, cabría esperar alrededor de una muerte adicional en las primeras 24 horas. Con el intervalo de Newcombe, el NND compatible con los datos va de 2,9 a 53, es decir, de un daño grande a uno pequeño.

Esa amplitud no impide una conclusión práctica. La dosis alta

era la intervención experimental y se justificaba por un beneficio esperado; el intervalo para la diferencia de riesgos excluye cualquier beneficio, y el exacto condicional para la razón de odds solo admite uno ínfimo. La decisión que el ensayo podía informar, no adoptar la dosis alta, no depende del procedimiento que se elija. Lo que sí depende de esa elección es la afirmación más fuerte, que la dosis alta causa daño, y es la que conviene formular con la cautela que imponen 34 niños por grupo y un único sobreviviente en uno de ellos.

En los tres planos —el contraste, el estimador y el intervalo— el patrón es el mismo. El procedimiento conservador compra una garantía (un tamaño que no supera α, un estimador sin sesgo, una cobertura mínima) y la paga con información (potencia, varianza, longitud). Las alternativas no eliminan ese costo, lo redistribuyen, y la redistribución adecuada depende de qué error resulta más caro en el problema clínico concreto, algo que debe decidirse antes de ver la tabla.

6. Hipótesis sobre el uso habitual de Fisher

Lo documentado es limitado pero concreto: Fisher está entre las pruebas más frecuentes de la literatura clínica (**Hellems2007**), las guías de lectura crítica lo recomiendan para muestras pequeñas (**duPrel2010**) y las alternativas incondicionales se conocen, al menos, desde **Barnard1945** y **Boschloo1970**. Por qué esa situación se mantiene es otra cuestión, que este trabajo no resuelve. Lo que sigue son hipótesis plausibles, no una explicación demostrada; ponerlas a prueba exigiría una revisión sistemática de los métodos declarados en ensayos pequeños, o encuestas a quienes los analizan.

La primera hipótesis es la tradición. Fisher ocupa un lugar central en la estadística del siglo XX, y la regla que manda revisar las frecuencias esperadas (**Cochran1954**) se enseña en los cur-

sos introductorios con Fisher como salida; la distinción entre la validez de una prueba y su adecuación a un diseño concreto suele llegar después, si llega. De ahí puede nacer una regla práctica —"celda pequeña, Fisher"— que el software refuerza: `fisher.test()` viene en la instalación base de R y ocupa un lugar visible en SPSS, SAS, Stata y las calculadoras clínicas, mientras que las alternativas incondicionales, implementadas por ejemplo en el paquete `Exact` (**RExact**), exigen instalación adicional, la elección de un ordenamiento y una justificación explícita. El procedimiento inmediatamente más disponible, naturalmente tiende a convertirse en el más usado.

A esto puede sumarse una dificultad cognitiva. Pensar estadísticamente exige sostener a la vez el mecanismo de muestreo, el estimando, la hipótesis, el procedimiento de contraste y el costo del error; la literatura sobre heurísticas y sesgos muestra que, bajo incertidumbre, las decisiones tienden a simplificarse (**Kahneman2011**). Fisher ofrece un relato simple: hay una tabla, hay un test exacto, hay un valor p. Las alternativas incondicionales exigen una historia más larga. Este mecanismo es coherente con lo que se sabe sobre simplificación de decisiones, pero no se ha comprobado para este caso.

Una tercera hipótesis son los incentivos institucionales. La ciencia clínica sigue operando con un sistema de recompensas ligado al valor p, pese a las declaraciones de la ASA (**WassersteinLazar2016**; **WassersteinSchirmLazar2019**), y la responsabilidad de la elección se reparte entre estadístico, investigador, revista, revisor y comunidad, sin que ningún eslabón cometa necesariamente un error individual. Conviene reconocer, sin embargo, que la resistencia a las alternativas no es solo inercia: Barnard–CSM exige definir un ordenamiento, Boschloo hereda decisiones sobre el valor p condicional, Berger–Boos depende del intervalo de confianza y de γ, y el mid-p sacrifica garantías. Parte de la persistencia de Fisher refleja una incertidumbre metodológica legítima, y Fisher

conserva además a su favor la lógica de la aleatorización (Sección 2). El problema aparece cuando esa incertidumbre sirve para evitar la comparación en lugar de motivar que se haga con más cuidado.

7. Hacia una práctica más explícita

La respuesta pasa por hacer visible la elección del modelo inferencial y por repartir la responsabilidad de esa elección antes de analizar los datos.

7.1. Declarar el diseño y separar la estimación del contraste

El primer paso es describir el mecanismo que generó los datos. ¿Se fijaron los tamaños de grupo y el total de respuestas quedó al azar, o los datos llegaron ya recolectados, sin ningún margen fijado, como en un muestreo transversal? ¿Hubo apareamiento, estratificación o asignación adaptativa? La tabla puede ser la misma y el modelo estadístico no. Si el mecanismo fue la aleatorización del tratamiento, existe además la vía de inferencia por asignación, que este trabajo deja de lado. Sin esa descripción, la elección del procedimiento es una costumbre con apariencia de decisión.

Declarar el diseño no basta. Un valor p no informa sobre la magnitud ni sobre la relevancia clínica del efecto. El informe debe incluir el estimando, los riesgos absolutos, una medida de efecto adecuada —diferencia de proporciones, razón de riesgos o razón de odds, según corresponda— y un intervalo de confianza compatible con el procedimiento elegido. Con muestras pequeñas, el carácter discreto del procedimiento y la definición del intervalo deben declararse explícitamente. También la esca-

la. En la tabla de Perondi, la razón de odds estimada va de 4,9 a 8,6 según el estimador, y bajo las proporciones observadas su estimador de máxima verosimilitud es infinito con probabilidad 0,36; la diferencia de riesgos apenas se mueve un punto porcentual (Sección 5.2). Cuando un brazo tiene muy pocos eventos, elegir la escala del estimando precede a elegir el estimador.

7.2. Comparar procedimientos antes de ver los datos

Cuando el diseño lo permita, conviene preespecificar una comparación entre Fisher, Boschloo, Barnard–CSM, Berger–Boos, mid-p o el m-test de **AraujoVocesQuesada2021**. Su propósito es medir cuán estable es la conclusión ante distintos supuestos sobre el espacio muestral y el ordenamiento; usarla para escoger el valor p más bajo sería una forma de selección *post hoc*. Si el veredicto cambia con el procedimiento, eso es parte del resultado, no algo que haya que ocultar.

El cálculo de potencia bajo escenarios plausibles ofrece un lenguaje común para hacer esa comparación. Se fijan los tamaños de grupo, las proporciones bajo H_0 y bajo una alternativa razonable, el mecanismo de muestreo y el nivel α; se enumeran todas las tablas posibles, como en la Sección 4.1, o, si son demasiadas, se simulan; se aplica cada procedimiento a cada tabla y se calcula la proporción de rechazos. Esa proporción estima la potencia del procedimiento en ese escenario.

Conviene no confundir esta potencia prospectiva con la "potencia observada", calculada a partir del efecto estimado en la misma muestra. La potencia observada es, en esencia, una transformación monótona del valor p y no aporta información nueva (**HoenigHeisey2001**; **LevineEnsom2001**). El cálculo prospectivo, en cambio, permite preguntar: si el efecto verdadero fuera este, ¿qué procedimiento lo detectaría con mayor frecuencia?

Esa pregunta es legítima, transparente y útil para planear estudios. Cuando ya existe un estudio previo, la potencia predictiva de la Sección 5.1 une ambos usos: promedia la potencia prospectiva sobre lo que ese estudio enseñó, sin tratar su estimación puntual como si fuera el valor verdadero.

¿Cómo se vería esta secuencia en el ensayo de **Perondi2004**? El diseño asignó 34 participantes a cada grupo y el número de sobrevivientes era un resultado aleatorio, de modo que el modelo natural son dos binomiales independientes. Antes de ver los datos, el plan de análisis habría declarado: (i) que el contraste principal usaría Boschloo bajo ese modelo; (ii) que Fisher se reportaría como prueba de aleatorización, es decir, como respuesta a la pregunta sobre los participantes del ensayo; (iii) que el efecto se resumiría con la diferencia de riesgos y un intervalo coherente con el contraste principal —con los datos observados, $[0{,}019;\ 0{,}340]$ con el método de Newcombe—; y (iv) que un cálculo como el de la Sección 4.1 caracterizaría la potencia y la discordancia esperadas bajo $p_1 = 0{,}20$, $p_2 = 0{,}03$ y $n = 34$. El informe habría mostrado, además de los valores p, que bajo ese escenario la probabilidad exacta de rechazo era 43,3 % para Fisher, 54,9 % para Boschloo y 58,7 % para CSM, y que algo más de uno de cada nueve conjuntos de datos con esas características produciría veredictos opuestos entre Fisher y Boschloo. Esa información pertenece al plan, no a una nota añadida después de revisar los datos.

7.3. Garantizar coherencia y repartir responsabilidades

El cálculo del tamaño muestral debería usar el mismo modelo inferencial que el análisis. Si el estudio se planeó bajo dos binomiales independientes, usar después un procedimiento que condiciona al total de respuestas requiere una justificación adicional, o debe presentarse como análisis de sensibilidad. La co-

herencia entre planificación y análisis protege tanto contra la falta de potencia como contra la apariencia de selección *post hoc*.

El software y la formación pueden reducir la fricción sin eximir de la responsabilidad. Las funciones deberían documentar el diseño que suponen, ofrecer opciones de ordenamiento y de estimación, devolver intervalos coherentes y advertir cuando el procedimiento elegido no coincide con el modelo más natural del diseño. En la formación, el estudiante debería aprender una secuencia de preguntas antes que un comando: ¿qué se fijó?, ¿qué es aleatorio?, ¿qué se quiere estimar?, ¿qué hipótesis se contrasta?, ¿cuánto cuesta equivocarse?

Por último, la responsabilidad debe repartirse, y quienes tienen más palanca práctica son las revistas y los comités de ética. Las revistas y sus revisores pueden pedir que se justifiquen el modelo de muestreo y el procedimiento elegido, en lugar de tratar a Fisher como un estándar que dispensa de argumentar. Los comités de ética pueden preguntar si el cálculo del tamaño muestral y el análisis planificado son coherentes, porque esa coherencia forma parte de la protección debida a los participantes. Financiadores y sociedades científicas también influyen —los primeros al valorar planes que preespecifiquen análisis de sensibilidad; las segundas al actualizar guías que todavía confunden exactitud numérica con adecuación al diseño—, pero son las revistas y los comités quienes deciden, en la práctica, qué análisis se publica y qué protocolo se aprueba. Ninguna de estas medidas basta por sí sola; juntas pueden modificar los incentivos que sostienen la costumbre.

7.4. Consecuencias éticas

La elección de la prueba no es solo metodológica, y el argumento puede hacerse explícito en tres pasos.

El primero es una premisa ya establecida en la ética de la investigación clínica. Un ensayo expone a sus participantes a riesgos y cargas, y parte de lo que justifica esa exposición es que el estudio pueda producir conocimiento. Por eso los ensayos con potencia insuficiente se han considerado éticamente problemáticos (**Halpern2002**), y los ensayos que no pueden responder su pregunta, una fuente de daño para los participantes y de desperdicio de recursos (**Zarin2019**).

El segundo paso es observar que la capacidad informativa de un ensayo no depende solo de cuántos participantes recluta, sino también de cómo se analizan sus datos. En el escenario de la Sección 4.1, un estudio analizado con Fisher dejaría pasar el efecto en el 56,7 % de los casos; analizado con Boschloo, en el 45,1 %. Dicho en la moneda que usan los comités de ética: para alcanzar con Fisher la potencia que Boschloo logra con 34 participantes por grupo (54,9 %), harían falta 40 por grupo (56,0 %): doce personas más en total. Cuando la pregunta es poblacional, elegir Fisher sin que el diseño lo justifique equivale, en ese escenario, a analizar el ensayo como si se hubiera reclutado a menos gente de la que de hecho asumió los riesgos.

El tercer paso es examinar la objeción natural: el conservadurismo protege contra los falsos positivos, que también causan daño cuando llevan a adoptar tratamientos inútiles. La objeción tiene peso, pero no alcanza a este caso. Boschloo ya garantiza que el error tipo I no supere el nivel nominal (Figura 4); el conservadurismo adicional de Fisher no es una protección que alguien haya decidido, sino un subproducto del carácter discreto de la hipergeométrica. Si se quiere más protección, lo coherente es declarar un α menor. En Perondi, además, la diferencia sugerida era un posible perjuicio de la dosis alta; si era real, el conservadurismo adicional no protegía a los pacientes, sino que hacía más difícil reconocerlo. Conviene precisar el alcance de esta observación: la decisión de no adoptar la dosis alta no dependía del procedimiento, porque con cualquiera de

ellos los datos excluyen un beneficio (Sección 5.4). Lo que el conservadurismo dificultaba era establecer el daño, y esa es la información que pesa cuando una práctica ya se usa o se recomienda.

El argumento tiene límites que conviene declarar. Vale cuando el diseño corresponde a dos binomiales independientes; no afirma que la elección de Fisher haya causado daño en ningún estudio concreto, y establecer su efecto sobre la literatura en conjunto requeriría un estudio empírico específico. Lo que sí sostiene es que la elección del procedimiento tiene consecuencias para los participantes; por eso su justificación no debería dejarse al software ni a la costumbre: forma parte de lo que se debe a quienes participaron, y su lugar es el protocolo y el informe.

8. Conclusión

El test exacto de Fisher sigue siendo una herramienta válida, y es la adecuada cuando la pregunta justifica condicionar a ambos márgenes, como ocurre al razonar desde la aleatorización. Lo que la enumeración exacta permitió medir es su costo cuando la pregunta es poblacional: en los diseños balanceados estudiados, donde la potencia de Fisher está entre 0,2 y 0,8, la ganancia mediana de Boschloo osciló entre 5 y 14 puntos porcentuales. Esa ganancia se concentra donde los eventos son raros en uno de los grupos, disminuye al crecer la muestra y se explica, en buena parte, por el nivel nominal que Fisher deja sin usar.

El ensayo de **Perondi2004** condensa lo que está en juego: con los mismos datos y el mismo umbral, la elección del procedimiento cambia el veredicto. Ninguno de los dos veredictos es un error; cada uno responde a una pregunta distinta. Lo que sí sería un error es no saber cuál de las dos se respondió. La

corrección que se desprende de este análisis es, en lo esencial, declarar antes de ver los datos qué cantidades fijó el protocolo y cuáles quedaron al azar, y a qué población se dirige la inferencia. Con esa respuesta puede decidirse si condicionar, maximizar o integrar sobre el parámetro nuisance, o aceptar una aproximación razonable; y puede decidirse también la definición del valor p bilateral, que en diseños desbalanceados cambia qué tablas se rechazan. Nada de esto obliga a abandonar el test de Fisher. Pide que usarlo sea una decisión argumentada y no una regla heredada, y que se acompañe de la estimación del efecto con su intervalo.

Esa estimación tiene, a su vez, sus propios compromisos. En la razón de odds el estimador sin sesgo no existe y los estimadores corregidos cambian varianza por sesgo; en los intervalos, la cobertura garantizada se paga con longitud. En ninguno de los tres planos —contraste, estimador, intervalo— la elección correcta se desprende de un óptimo calculado en el punto estimado: la corrección que minimiza el error en ese punto deja de ser la mejor cuando se promedia sobre lo que no se sabe. En Perondi, esa cautela no impide una lectura clínica clara: los datos excluyen un beneficio de la dosis alta, que era la razón para probarla, y dejan abierta la magnitud del daño.

El trabajo deja también a la vista un límite propio. Los procedimientos incondicionales dependen de que la maximización sobre el parámetro nuisance se resuelva bien, y en el software corriente se resuelve por malla o por búsqueda numérica. La tabla de Perondi lo muestra en pequeño: un máximo local o una tabla entregada con la orientación equivocada producen valores plausibles y erróneos, sin que el programa lo advierta (Sección 4). Hay, sin embargo, una vía para cerrar ese margen. Para cada tabla, la cola que se maximiza es un polinomio en p de grado $n_1 + n_2$, y un polinomio puede acotarse entre los nodos de una malla; en principio, el máximo global puede certificarse y no solo aproximarse. No se exploró aquí, y queda como la ex-

tensión natural de este trabajo. Mientras tanto, una respuesta aproximada a la pregunta correcta —¿qué fijó el diseño?— sigue valiendo más que un valor *p* exacto para una pregunta que nadie formuló.

A. Complementos de la Sección 5

A.1. Notación

La Tabla 7 reúne los símbolos y siglas de la Sección 5. Todas las esperanzas son sumas finitas sobre las 35×35 tablas posibles: para una función g de la tabla,

$$\mathrm{E}_{p_1,p_2}[g(X)] = \sum_{x_1=0}^{34} \sum_{x_2=0}^{34} g(x_1, x_2)\ \Pr(X_1 = x_1)\,\Pr(X_2 = x_2).$$

Tabla 7: Símbolos y siglas de la Sección 5.

Símbolo o sigla	Significado
x_i, n_i, $\hat{p}_i$	Sobrevivientes a 24 horas, tamaño y proporción observada del grupo i; $\hat{p}_i = x_i/n_i$, con $x_1 = 7$, $x_2 = 1$, $n_1 = n_2 = 34$.
p_1, p_2	Probabilidades verdaderas de supervivencia con dosis estándar y con dosis alta.
logit p	$\log\{p/(1-p)\}$, logaritmo de las odds.
OR, θ	Razón de odds y su logaritmo, $\theta = \log \mathrm{OR} = \operatorname{logit} p_1 - \operatorname{logit} p_2$.
DR, Δ	Diferencia de riesgos, $\Delta = p_1 - p_2$.
NND	Número necesario para dañar, $1/\Delta$: pacientes tratados con dosis alta por cada muerte adicional a 24 horas.
$\varphi(x)$	Función de decisión de una prueba: probabilidad de rechazar H_0 al observar la tabla x; vale 0 o 1, salvo en la prueba aleatorizada.
$\beta_\varphi(p_1, p_2)$	Probabilidad de rechazo, $\mathrm{E}_{p_1,p_2}[\varphi(X)]$: tamaño si $p_1 = p_2$, potencia si $p_1 \neq p_2$.
α, γ	Nivel nominal (0,05) y penalización de Berger–Boos (0,001).
c, $\hat{\theta}_c$	Corrección aditiva por celda y el estimador resultante.
EMV, EMVC	Estimador de máxima verosimilitud incondicional y condicional a los márgenes.
ECM	Error cuadrático medio, $\mathrm{E}[(\hat{\theta} - \theta)^2] = \text{sesgo}^2 + \text{varianza}$.
IC, $C(p_1, p_2)$	Intervalo de confianza al 95 % y su cobertura, $\Pr_{p_1,p_2}(\theta \in \mathrm{IC})$.
$\pi(p_1, p_2 \mid x)$	Distribución posterior con a priori de Jeffreys, $\mathrm{Beta}(\frac{1}{2}, \frac{1}{2})$, en cada brazo: $\mathrm{Beta}(7{,}5;\ 27{,}5) \times \mathrm{Beta}(1{,}5;\ 33{,}5)$.
Potencia media	β_φ promediada uniformemente sobre $0{,}15 \leq p_1 \leq 0{,}35$, $p_2 \leq 0{,}10$.
Potencia predictiva	$\int \beta_\varphi(p_1, p_2)\, \pi(p_1, p_2 \mid x)\, dp_1\, dp_2$.

A.2. Por qué la media posterior de Jeffreys se aleja de cero

La media posterior de θ con a priori de Jeffreys tiene un sesgo de $+0{,}41$ en $(\hat{p}_1, \hat{p}_2)$: se aleja de cero en lugar de acercarse. La razón es de escala. Una a priori poco informativa sobre p no lo es sobre $\operatorname{logit} p$. Con un solo evento en el grupo de dosis alta, la posterior de p_2 es $\mathrm{Beta}(1{,}5;\ 33{,}5)$, y la esperanza posterior de su logit, $\psi(1{,}5) - \psi(33{,}5) \approx -3{,}46$, es más extrema que el logit de la media posterior, $\operatorname{logit}(1{,}5/35) \approx -3{,}11$. Lo bayesiano no regulariza por sí mismo: regulariza la a priori, y solo en la escala en que se formula.

A.3. Cobertura de los intervalos para θ

El intervalo de Woolf con $c = \frac{1}{2}$ es $\hat{\theta}_{1/2} \pm 1{,}96\,\{\sum_{ij}(x_{ij} + \frac{1}{2})^{-1}\}^{1/2}$, donde x_{ij} son las cuatro celdas de la tabla; el exacto condicional invierte la hipergeométrica no central. Sobre la rejilla $0{,}02 \le p_1, p_2 \le 0{,}50$, la cobertura de Woolf fue en promedio $0{,}961$, con un mínimo de $0{,}926$; la del exacto condicional, $0{,}978$ en promedio, con un mínimo de $0{,}968$. Promediadas sobre la posterior, $0{,}954$ y $0{,}988$. La Figura 6 muestra dos cortes por el escenario de referencia: con $p_1 = 0{,}20$ fijo, la cobertura de Woolf cae a $0{,}876$ cuando $p_2 = 0{,}005$. La longitud esperada del intervalo de Woolf en $(\hat{p}_1, \hat{p}_2)$ es $4{,}28$ en escala logarítmica, es decir, un cociente de cerca de 72 entre sus límites.

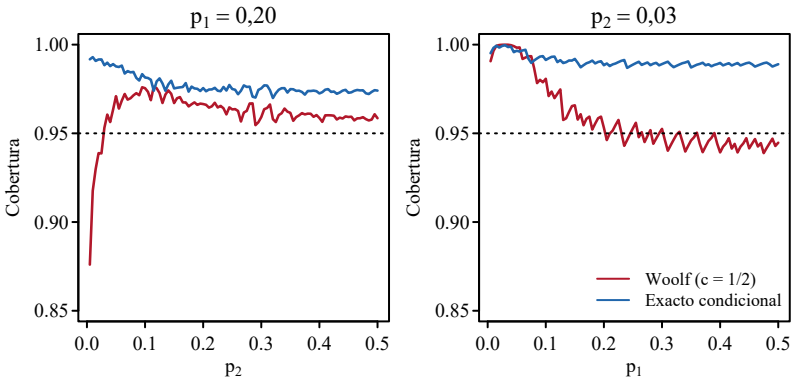


Figura 6: Cobertura exacta de dos IC al 95 % para θ en dos cortes que pasan por el escenario de referencia: $p_1 = 0{,}20$ fijo (izquierda) y $p_2 = 0{,}03$ fijo (derecha). La línea punteada marca 0,95.

A.4. Reproducibilidad

Todas las cifras de la Sección 5 y de este apéndice se obtienen con el guion `sesgo_varianza.R`, que usa solo R base (verificado en las versiones 4.3.3 y 4.6.1) y escribe sus resultados en la carpeta `sesgo_varianza`. Los valores p incondicionales se maximizan sobre una malla de 1999 valores del parámetro nuisance, con la tolerancia de empates de `fisher.test`; los de la prueba z y de Boschloo coinciden con los de la Sección 4. La posterior se discretiza en una rejilla de paso 0,0025. Berger–Boos se calculó con $\gamma = 0{,}001$; el valor $\gamma = 10^{-4}$ que recomiendan **LydersenLangaasBakke2012** para la prueba z no cambiaría las decisiones en este diseño, porque las de Boschloo y Berger–Boos ya coinciden en las 1225 tablas.